3 解决方案

3.1 问题阐述

知识追踪任务是基于学生历史交互序列预测未来表现的序列建模问题。

设$\mathcal{H} = (q_i, r_i, c_i, L_i)$表示一名学生的历史交互序列，其中$q_i$代表习题，$r_i \in \{0,1\}$表示第$i$步作答的作答结果,

c_i为题目所涉及的知识点集合，L_i为对应的认知层级。给定目标问题q_t，任务目标是估计学生答对该问题的概率，记为$P(r_t = 1|\mathcal{H}, q_t)$。

与传统的深度知识追踪（Deep Knowledge Tracing, DKT）仅依赖离散的题目 ID 进行序列编码不同，本文提出了名为 Cognitive-RAG 的特征增强框架。本文认为：当前知识追踪面临的关键问题，并不是缺少学生历史信息，而是如何从长历史中发现真正有教学价值的认知证据，并以低噪声、可对齐、可注入的形式服务于当前预测任务。围绕这一核心问题，本文将整个方案组织为四个彼此衔接的部分：首先构建多源认知先验库，为题目、学生与知识关系提供统一的先验支撑；然后设计两阶段认知证据检索器，从长历史中筛选出满足认知逻辑的高价值教学证据；接着通过分层认知上下文构造器，将检索证据组织为“全局摘要 + 局部证据”的结构化上下文；最后通过稳态认知语义融合器，将外部认知语义以可控方式注入知识追踪主干，实现对学生知识状态的稳定增强建模。

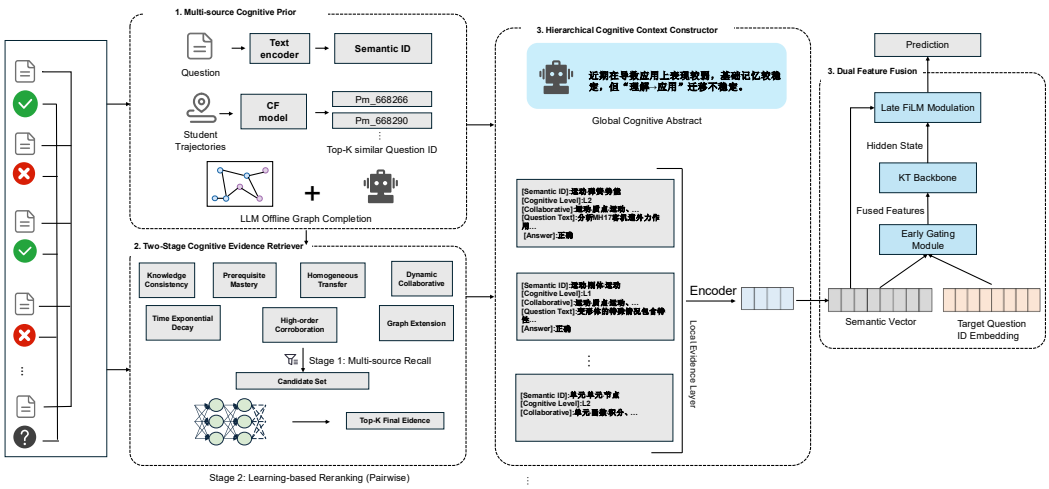

3.2 多源认知先验库

本文在正式检索之前构建一个多源认知先验库。核心思想是：不将学生历史交互视作一组孤立的题目记录，而是预先为每道题目和每个学生状态补充多层次的认知先验，使后续检索过程能够同时利用题目语义、群体协同、显式知识结构以及学生近期状态四类信息，从而为高价值教学证据的发现提供统一支撑。与传统仅依赖离散题目 ID 或单一路径相似度检索的方式不同，多源认知先验库的作用不是直接替代知识追踪主干模型，而是为后续的认知证据检索器提供结构化、可解释、可复用的检索基础。

本文从题目静态属性与学生动态认知状态两个层面构建多源认知先验。

首先，对于题目本身，构建与学生无关的静态先验表示：

$$\mathbf{P}_q^{static} = [\tilde{\mathbf{e}}_q^{sem}, \mathbf{e}_q^{collab}, \mathbf{e}_q^{graph}]$$

其中分别对应增强语义先验、隐式协同先验与显式图结构先验。上述表示均可通过离线方式预计算并缓存，构成题目级的静态认知表征库。

在此基础上，针对具体学生在当前时间步的认知状态，引入动态认知先验：

$$\mathbf{d}_{u,q,t} = \mathbf{e}_{u,q,t}^{diag}$$

其中$\mathbf{e}_{u,q,t}^{diag}$表示学生$u$在时间步$t$相对于题目$q$的短期认知诊断表示，由其最近交互窗口中的历史行为动态生成。

最终，在后续检索与推理过程中，题目相关的认知信息由静态先验$\mathbf{P}_q^{static}$与动态认知状态$\mathbf{d}_{u,q,t}$共同构成，而非简单地将所有信息视为题目级固定表示。

在题目级语义先验部分，本文在原有分层语义 ID 与题干语义表示的基础上，进一步引入基于 Rasch 模型的题目难度参数，用于刻画同一概念内部不同题目的个体差异。具体地，将题目级语义先验改写为：

$$\tilde{\mathbf{e}}_q^{sem} = \mathbf{e}_q^{sem} + \mu_q \mathbf{d}_{c(q)}$$

其中，$\mathbf{e}_q^{sem}$为原方案中由题干文本、分层语义 ID 等信息构造得到的题目语义表示；$\mu_q \in \mathbb{R}$为题目q的标量难度参数；$\mathbf{d}_{c(q)} \in \mathbb{R}^D$为题目所属概念的变化方向

向量，用于表征同一概念下题目差异的主要变化方向；$c(q)$表示由题目知识点集合聚合得到的概念表示。

这样的设计并不为每道题单独学习一整套完全独立的高维表示，而是在保留概念共享结构的前提下，仅额外引入一个标量难度参数 μ_q及概念侧变化方向 $\mathbf{d}_{c(q)}$。因此，它能够在参数规模可控的条件下显式建模同一概念下不同题并不完全等价这一事实，使题目级语义先验不仅保留原有的文本语义和层级语义信息，也能够反映题目在难度上的个体差异。

1. 题目级语义先验

分层语义 ID：传统的知识追踪模型通常采用随机初始化的数值或自增 ID 来表征习题。这类离散 ID 无法向模型传递任何题目的语义先验信息；而直接将过长的原始题干文本全部塞入模型，又会引发严重的计算瓶颈与注意力分散。为此，本文设计了一种分层语义 ID 构建算法，使习题 ID 本身即具备从学科领域到细粒度概念的语义分层结构。在此基础上，再通过上式引入题目难度参数μ_q，使题目级语义先验不仅回答“这道题属于什么语义类别”，还能够进一步刻画“这道题在所属概念内部偏易还是偏难”。

具体构建过程分为以下三个阶段：

阶段一：文本向量化

首先，提取所有习题的文本内容$Content(q_i)$，并利用针对中文与多语言优化的预训练检索模型（bge-small-zh-v1.5），将可变长度的自然语言文本映射为固定维度的语义向量$\mathbf{z}_i \in \mathbb{R}_c^d$。该过程有效地将符号空间的习题转换到了连续的语义度量空间中。

阶段二：双层 K-Means 聚类

为了构建具有层级关系的分类体系，本文对所有习题向量执行双层 K-Means 聚类算法。

全局粗聚类：在第一层级，对全体样本集进行 K-Means 聚类，将其划分为 K_{top}个宏观簇，捕捉粗粒度的学科差异。

局部细聚类：在第二层级，针对每一个宏观簇内部的样本，再次应用 K-Means 算法将其划分为K_{sub}个微观簇，以进一步区分同一章节下不同知识点的细微语义差异。

阶段三：基于 c-TF-IDF 的自然语言映射

为了将聚类结果无缝接入预训练文本编码器的语义空间，避免引入缺乏语义的聚类编号，本文采用基于类别的 c-TF-IDF（Class-based TF-IDF, c-TF-IDF）算法对簇进行自然语言命名。具体而言，将同一个微观簇内的所有题干文本视为一篇聚合文档，经过中文分词与停用词过滤后，计算每个词汇w的 c-TF-IDF 权重：

$$W_{c-TF-IDF}(w,c) = \frac{f_{w,c}}{|c|} \times \log\left(1 + \frac{N}{\sum_{c' \in C} I(w \in c')}\right)$$

其中，$f_{w,c}$为词汇w在簇c中的词频，N为总簇数。选取权重最高的自然语言 Token 作为该簇的代表性标签。将第一层提取的宏观标签T_{top}与第二层提取的微观标签T_{sub}进行字符串拼接，生成最终的分层语义 ID。

通过上述机制，每道习题被赋予了一个高度浓缩的自然语言 ID。该 ID 既保持了优秀的压缩率，又使得语义相似的题目在文本层面上共享相同的前缀，从而极大降低了下游模型进行特征对齐与类比推理的学习成本。

2. 隐式协同先验

基于交互序列的群体行为信号

仅依赖显式知识点或题干语义，往往难以覆盖学生群体中潜在的做题路径与行为模式。尤其在知识点标注不完整、题目文本表达差异较大或显式认知匹配较弱时，题目之间仍可能因为学生群体的共同行为而表现出稳定的关联性。

本文将全体学生的历史作答序列视作行为语料，将交互对象视为序列中的上下文单元，学习题目之间的低维协同表示。对于任意目标题目q_t，系统可在协同空间中检索出一组行为上相近的候选邻居，记为$c(q_t)$。这些邻居不必与目标题在知识点集合上完全重合，但它们往往反映了学生群体在真实学习过程中形成的隐式路径、常见过渡与共现模式。因此，隐式协同先验主要用于弥补显式认知匹配不足时的召回盲区，在后续检索阶段充当认知断层补充器，而非替代显式教育逻辑。

3. 显式图结构先验

本文以细粒度知识点为图谱节点，以前置依赖关系、同质关系及局部邻接关系（章节相邻/做题路径相邻/共现关系）为边，构建一个面向题目检索的轻量知识结构图。对于任意题目q，其显式图结构先验记为$g(q)$，表示与其相关的知识点邻域及关系路径。与直接采用复杂图神经网络不同，本文更强调图谱的先验约束功能：一方面，图谱可以为后续召回阶段提供概念扩展路径，使那些与目标题知识点不完全重合但存在明确教育关联的题目进入候选集合；另一方面，图谱可以为后续排序阶段提供关系解释，使系统能够区分“知识一致性”、“前置支撑”、“同质迁移”等不同类型的历史证据。

4. LLM 离线补全图谱

在真实教育数据中，显式标注的知识关系往往是不完备的，部分知识点之间存在潜在依赖，但数据集中未必已经显式给出；部分题目虽然在文本与行为上表现出强关联，也可能缺少明确的结构性连接。

具体地，对于现有图谱中缺失或不确定的候选关系，系统可离线调用大模型，根据知识点定义、题目文本和已有邻接结构生成潜在依赖边建议。随后，这些候选边需要经过规则校验、阈值过滤后，才能并入最终图谱。

3.3 两阶段认知证据检索器

在多源认知先验库的支撑下，本文进一步设计两阶段认知证据检索器，用于从学生冗长的历史交互序列中发现对当前目标题目最具解释力的教学证据。该模块的核心目标不是简单寻找“看起来相似”的历史记录，而是围绕当前预测任务，从历史中筛选出在概念上相关、在认知上合理、在时间上有效、在行为上可补充的证据子集。与传统单阶段加权检索不同，本文将检索过程显式拆分为“候选召回”和“证据精排”两个阶段：前者强调覆盖率与认知合理性，后者强调排序精度与证据价值判别。通过这种方式，系统既避免纯规则检索过于僵硬，也避免纯学习式检索失去教育可解释性。

单阶段检索存在两个矛盾。若过分依赖显式认知规则，则检索结果虽然可解释，但容易遗漏那些概念标注不完整、文本差异较大却在行为上具有强参考价值的历史题目；若完全依赖向量相似度或学习式排序，则虽然可能提高召回灵活性，却容易引入教育语义不合理的噪声记录。

第一阶段负责在严格认知约束下找全潜在证据，避免高价值样本在最初就被漏掉；

第二阶段负责对候选集合进行证据价值精排，从中筛出最能解释当前预测的少量教学证据。

3.3.1 第一阶段：基于显式认知规则与多源特征的粗召回

第一阶段的目标，是从学生的完整历史中快速构建一个规模适中的候选集合$\mathcal{C}_u^t$，使其中尽可能覆盖对当前目标题目有潜在价值的历史记录。与普通检索不同，本文的候选召回并不依赖单一路径，而是在多源认知先验库的基础上联合使用显式概念重合、认知层级约束、图谱扩展路径与隐式协同行为四类线索，从而形成多路并行的候选扩展机制。

给定学生u在时刻t之前的历史交互序列：

$$\mathcal{H}_u^{t-1} = \{h_1, h_2, \dots, h_{t-1}\}, h_i = (q_i, r_i, \tau_i)$$

其中q_i表示历史题目，r_i表示作答结果，τ_i表示序列位置；给定当前目标题目q_t，系统需要从$\mathcal{H}_u^{t-1}$中召回一个规模适中的候选集合$\mathcal{C}_u^t$。

与传统仅依赖文本相似度或固定窗口截断的方式不同，本文在候选召回阶段引入显式概念关系、认知层级关系、结构扩展关系、协同行为关系与时间有效性五组信号。这些特征共同构成候选召回的认知基础，也为下一阶段的学习式精排提供统一输入。在定义知识一致性、前置支撑、同质迁移、高阶佐证、图谱扩展和协同关联等基础特征后，记任意历史记录i的基础召回分数为$R_{\text{base}}(h_i, q_t)$。

（1）知识一致性

首先，本文利用细粒度知识点集合之间的交并关系来度量历史题目与目标题目在概念层面的直接重合程度。对于任意历史题目q_i，定义知识一致性为：

$$S_k(q_i, q_t) = \frac{|\mathcal{K}(q_i) \cap \mathcal{K}(q_t)|}{|\mathcal{K}(q_i) \cup \mathcal{K}(q_t)|}$$

该项本质上是基于 Jaccard 相似度的知识一致性度量，用于刻画历史题与目标题是否考查了相同或局部重合的细粒度概念。它承担的是显式概念重合检测的作用，而不是完整教育相似性的全部定义。

（2）前置支撑

定义历史题掌握度M_i。前置支撑和同质迁移的价值，不只取决于层级方向，还取决于学生在该历史题上的实际表现与掌握情况；而 3.2 已经给到短期认知诊断先验$\mathbf{e}_{u,q}^{diag}$。所以最自然的做法是把真实作答结果和诊断先验合成一个掌握度：

$$M_i = (1-\beta_d)\, r_i + \beta_d\, \sigma\left(\mathbf{w}_d^\top \mathbf{e}_{u,q_i}^{diag} + b_d\right), M_i \in [0,1]$$

这里 $\beta_d \in [0,1]$控制观测到的答对/答错和短期诊断先验的权重。

当历史题的认知层级低于目标题时，该历史题更可能承担基础支撑作用，反映学生是否已经掌握完成当前任务所依赖的低层级知识。定义认知层级差：

$$\Delta L_i = L(q_t) - L(q_i)$$

$\Delta L_i > 0$表示历史题更低层，$\Delta L_i = 0$表示同层，$\Delta L_i < 0$表示历史题更高层。

因此，若$L(q_i) < L(q_t)$，则该历史记录被视为候选的前置支撑证据。其价值不仅取决于层级方向是否合理，还取决于学生在该历史题上的实际表现与掌握情况。前置支撑可表示为：

$$S_p(h_i, q_t) = \mathbf{1}[\Delta L_i > 0] \cdot S_k(q_i, q_t) \cdot \exp\left(-\alpha_p(\Delta L_i - 1)\right) \cdot M_i$$

其中，$\mathbf{1}[\Delta L_i > 0]$保证只有历史题层级更低的记录才算前置支撑；$S_k(q_i, q_t)$保证它和目标题在概念上确实有关；$\exp\left(-\alpha_p(\Delta L_i - 1)\right)$表示层级差越大，前置支撑价值通常越弱；$M_i$表示学生在这道低层级历史题上学得越扎实，这条支撑证据越可信。

（3）同质迁移

当历史题与目标题处于相同认知层级时，二者更可能属于同类任务，历史表现可以为当前预测提供直接类比依据。因此，若$L(q_i) = L(q_t)$，则该历史记录被视为同质迁移证据。这类证据主要回答“学生在与当前任务难度和认知要求相当的题目上表现如何”。

定义增强语义相似度：

$$A_i = \frac{1 + \cos(\tilde{\mathbf{e}}_{q_i}^{sem}, \tilde{\mathbf{e}}_{q_t}^{sem})}{2}, A_i \in [0,1]$$

同质迁移可表示为：

$$S_m(h_i, q_t) = \mathbf{1}[\Delta L_i = 0] \cdot (\eta_k\, S_k(q_i, q_t) + (1-\eta_k)\, A_i) \cdot M_i, \eta_k \in [0,1]$$

（4）高阶佐证

当历史题的认知层级高于目标题时，它不再适合作为前置支撑证据，也不属于严格意义上的同质迁移证据；但这并不意味着它完全无效。若学生在更高层级、且与目标题概念相关的历史题上表现良好，则该记录可以作为一种反向佐证，说明学生可能已经具备完成较低层级任务的能力。相反，若学生在更高层级题上失败，这一结果只能视为较弱的负向参考，因为其失败原因可能来自高层推理不足，而不一定意味着低层基础知识缺失。因此，本文将$L(q_i) > L(q_t)$的历史记录统一视作高阶佐证证据。

高阶佐证可表示为：

$$S_h(h_i, q_t) = \mathbf{1}[\Delta L_i < 0] \cdot S_k(q_i, q_t) \cdot \exp(-\alpha_h(|\Delta L_i| - 1)) \cdot \big(r_i - \rho_h(1 - r_i)\big),$$

$$\rho_h \in (0,1)$$

当$r_i = 1$时，最后一项等于1，表示高层成功是强正向佐证；

当$r_i = 0$时，最后一项等于$-\rho_h$，表示高层失败只是弱负向参考，而不是强烈否定。

（5）图谱扩展信号

除直接的概念重合外，某些历史题虽然与目标题不共享完全相同的知识点集合，但在轻量教育知识图谱中与其存在前置依赖、同质关系或教学邻近关系，仍具有潜在教学价值。

当图谱扩展信号被使用时，说明历史题虽然未必与目标题发生直接概念重合，但至少在显式知识结构上处于与目标相关的局部邻域中，可作为候选扩展来源。

先定义知识图谱中任意两个知识点 a, b的原始关系分数：

$$\phi(a, b) = \omega_{\mathrm{rel}(a,b)} \cdot \exp\Big(-\beta_g\,(d_G(a, b) - 1)\Big),$$

其中，$d_G(a, b)$是图上的最短路径长度；$\mathrm{rel}(a, b)$表示边或主路径对应的关系类型；ω_{rel}是关系类型权重。

例如，你可以设置：

$$\omega_{\mathrm{pre}} > \omega_{\mathrm{same}} > \omega_{\mathrm{adj}} > 0,$$

分别对应前置依赖、同质关系、局部邻接关系。

然后把题目层的图谱扩展定义为：

$$\bar{S}_g(q_i, q_t) = \max_{a \in \mathcal{K}(q_i),\, b \in \mathcal{K}(q_t)} \phi(a, b)$$

再进一步，为了避免它和 S_k重复计算直接概念重合，建议最终写成：

$$S_g(q_i, q_t) = (1 - S_k(q_i, q_t)) \cdot \bar{S}_g(q_i, q_t)$$

这样一来，直接重合的题主要由S_k负责；图谱扩展只在概念不完全重合但显式结构相关时起补充作用

（6）协同关联信号

当显式概念重合和认知层级匹配不足时，仅靠知识点关系可能导致候选过于稀疏。为此，本文引入由交互序列预处理阶段得到的隐式协同先验，利用题目在群体作答行为中的潜在共现规律补足召回盲区。

该项刻画历史题与目标题在隐式协同行为层面的接近程度。需要强调的是，协同关联信号在本文中并不替代显式教育逻辑，而是作为显式认知匹配不足时的补充支路。

协同关联可表示为：

$$S_{cf}(q_i, q_t) = \frac{1 + \cos(\mathbf{e}_{q_i}^{collab}, \mathbf{e}_{q_t}^{collab})}{2}, S_{cf} \in [0,1]$$

先定义一个显式匹配强度：

$$E_i^{\exp} = \eta_1 S_k(q_i, q_t) + \eta_2 \exp\left(-\beta_L |L(q_i) - L(q_t)|\right) + \eta_3 S_g(q_i, q_t)$$

$$\eta_1 + \eta_2 + \eta_3 = 1$$

然后定义：

$$\lambda_i = 1 - \mathrm{clip}(E_i^{\exp}, 0, 1)$$

这意味着：显式概念重合越强、层级越接近、图谱结构越明确，λ_i越小，协同信号越不需要出头；反过来，如果这些显式证据都比较弱，λ_i就会变大，协同关联S_{cf}才会真正放大。

在定义上述基础特征后，本文构造第一阶段的基础召回分数：

$$R_{\text{base}}(h_i, q_t) = w_k\, S_k(q_i, q_t) + w_p\, S_p(h_i, q_t) + w_m\, S_m(q_i, q_t) + w_h\, S_h(h_i, q_t) + w_g\, S_g(q_i, q_t) + \lambda_i\, S_{cf}(q_i, q_t)$$

其中S_k表示知识一致性，S_p表示前置支撑信号，S_m表示同质迁移信号，S_h表示高阶佐证信号，S_g表示图谱扩展信号，S_{cf}表示协同关联信号，λ_i为协同信号的动态系数。

基础召回分数由知识一致性、认知层级关系、图谱结构相关性和协同关联共同决定，其中知识一致性负责捕捉显式概念重合，前置支撑、同质迁移与高阶佐证共同刻画不同方向的认知层级关系，图谱扩展用于补充结构相关但不直接重合的题目，动态协同关联用于在显式证据不足时弥补认知断层；最终再由时间有效性对历史证据的时效性进行整体校正。

除知识一致性、层级关系和结构关联外，历史证据是否仍能反映学生当前状态，还取决于其与当前预测时刻之间的时间关系。一般而言，历史记录距离当前越远，其对当前作答判断的参考价值越弱；尤其在学习间隔较长时，学生已掌握知识可能因遗忘而发生衰减。基于这一认识，本文在候选召回阶段引入时间有效性信号，用于刻画历史证据的时效性。

具体地，定义历史记录i的时间有效性为：

$$T_i = \exp(-\theta\, d(t,i))$$

其中$\theta > 0$为衰减系数，$d(t,i)$为目标题条件化的有效距离。最终，第一阶段的召回分数写为：

$$R_{recall} = R_{base} \cdot exp\,(-\theta d)$$

这里的关键不是简单采用绝对时间差，而是使用与当前目标题相关的上下文感知距离。具体定义为：

$$d(t,i) = \mid t - i \mid \sum_{j=i+1}^{t-1} \gamma_{t,j}$$

其中

$$\gamma_{t,j} = \frac{\exp(\mathrm{sim}\,(\tilde{\mathbf{e}}_{q_t}^{sem}, \tilde{\mathbf{e}}_{q_j}^{sem}))}{\sum_{m=1}^{t-1} \exp(\mathrm{sim}\,(\tilde{\mathbf{e}}_{q_t}^{sem}, \tilde{\mathbf{e}}_{q_m}^{sem}))}$$

其中，$\mathrm{sim}\,(\cdot,\cdot)$表示基于题目级语义先验的相似度函数，$\tilde{\mathbf{e}}_{q_t}^{sem}$与 $\tilde{\mathbf{e}}_{q_j}^{sem}$分别表示当前目标题与历史题目的增强题目级语义先验。由于 3.2 已在题目级语义先验中引入题目难度参数μ_q，因此这里的相关性不仅考虑题目语义与概念层面的接近程度，也保留了同概念内部的题目差异。

在得到所有历史记录相对于当前目标题目q_t的粗召回分数后，本文按照$R_{\text{recall}}(h_i, q_t)$对学生历史交互序列$\mathcal{H}_{u,<t}$中的全部候选记录进行降序排序，并从中选取得分最高的前K_1条，构成第一阶段输出的候选集合：

$$\mathcal{C}_t = \{\, h_i \in \mathcal{H}_{u,<t} \mid \text{rank}\,(S_i^{recall}) \leq K_1 \,\}$$

其中，K_1表示第一阶段保留的候选规模；rank $(\cdot)$ 表示按粗召回分数从高到低的排序位置。通过该步骤，系统将完整历史中在概念关系、认知层级、结构邻域、协同行为与时间有效性上具有潜在价值的历史记录压缩为一个规模可控的候选子集，以供第二阶段进一步执行覆盖约束下的证据精排。这里得到的 $\mathcal{C}_t$并不追求一步到位的最终最优排序，而是强调尽可能保留对当前预测任务可能有用的高价值历史证据，从而在召回率与后续计算开销之间取得平衡。

3.3.2 第二阶段：认知证据覆盖式精排

第二阶段的目标是进一步从中筛出少量最具解释力的高价值教学证据。第一阶段解决的是哪些历史记录可以进入视野，第二阶段解决的则是在这些候选中，哪些最能帮助判断学生当前是否能答对目标题目。

第一阶段得到的候选集合C_u^t已经尽可能覆盖了与当前目标题目q_t在知识一致性、认知层级关系、图谱结构关联、协同行为和时间有效性上具有潜在价值的历史记录。然而，候选集合可能存在两个问题：一是高分候选在知识内容或认知角色上高度重复，容易冗余；二是不同类型的教学证据可能分布不均，导致最终证据集过度集中于某一类关系，而缺失对当前预测同样重要的前置支撑、同质迁移、高阶佐证或图谱扩展信息。因而，第二阶段的目标不再是重新判断哪些历史记录与当前题目相关，而是从候选集合中进一步选择一组高效证据、覆盖充分且低冗余的最终认知证据。

本文在第二阶段采用一种认知覆盖约束精排策略。该策略直接复用第一阶段已经得到的显式认知特征，在候选集合上执行面向集合质量的贪心选择。其核心思想是：最终证据集不应只是若干单点高分历史记录的简单截断，而应是一个在教学功能上相互补充、在知识内容上避免重复、在认知逻辑上更完整的小规模证据子集。

在第二阶段中，本文并未重新定义各类认知信号，而是直接复用第一阶段中已经计算得到的各项得分，并在统一表示下构造基础证据效用分数。对于候选集合中的任意历史记录 h_i，定义其基础效用为：

$$U_i = \alpha_k S_k(q_i, q_t) + \alpha_p S_p(h_i, q_t) + \alpha_m S_m(h_i, q_t) + \alpha_h S_h(h_i, q_t) + \alpha_g S_g(q_i, q_t) + \alpha_c \lambda_i S_{cf}(q_i, q_t)$$

其中S_k, S_g, S_{cf}仅依赖题目对(q_i, q_t)；S_p, S_m, S_h同时依赖历史交互记录$h_i = (q_i, r_i, \tau_i, \dots)$，用于刻画学生在该题上的真实认知表现；$\lambda_i$为基于显式认知匹配强度动态调节的协同信号权重。$\alpha_k, \alpha_p, \alpha_m, \alpha_h, \alpha_g, \alpha_c$为非负权重系数。该分数用于衡量单条候选历史记录对当前目标题目的独立解释价值。需要说明的是，第二阶段未再单独引入时间有效性项，而是直接基于第一阶段已完成时间校正后的候选集合进行精排，从而避免时间因素被重复计入。

仅依据U_i进行 Top-K 截断仍会带来显著冗余，因此本文进一步在集合层面引入认知覆盖增益。设当前已选证据集合为$S \subseteq C_u^t$，对于候选h_i，其覆盖增益定义为：

$$\mathrm{Cov}(h_i \mid S) = \eta_p \Delta_p(i, S) + \eta_m \Delta_m(i, S) + \eta_h \Delta_h(i, S) + \eta_k \Delta_k(i, S) + \eta_g \Delta_g(i, S)$$

其中，$\eta_p, \eta_m, \eta_h, \eta_k, \eta_g$为覆盖项权重。各增量项分别表示候选$h_i$对当前证据集在不同维度上的新增贡献：$\Delta_p(i, S)$ 表示其对前置支撑证据覆盖的补充程度，$\Delta_m(i, S)$ 表示其对同质迁移证据覆盖的补充程度，$\Delta_h(i, S)$ 表示其对高阶佐证证据覆盖的补充程度，$\Delta_k(i, S)$ 表示其带来的新增知识点覆盖，$\Delta_g(i, S)$ 表示其带来的新增图谱邻域覆盖。通过这一设计，第二阶段不再单纯偏向最相似的候选，而是显式鼓励最终证据集同时保留不同教学角色的代表性历史记录。

为便于实现，可进一步定义候选h_i的关系激活指示量：

$$a_i^p = \mathbb{I}\left[S_p(h_i, q_t) > 0\right], \qquad a_i^m = \mathbb{I}[S_m(q_i, q_t) > 0],$$

$$a_i^h = \mathbb{I}[S_h(h_i, q_t) > 0], \qquad a_i^g = \mathbb{I}[S_g(q_i, q_t) > 0]$$

在此基础上，关系覆盖增量可写为

$$\Delta_c(i, S) = \min\left(1, \sum_{h_j \in S} a_j^c + a_i^c\right) - \min\left(1, \sum_{h_j \in S} a_j^c\right), c \in \{p, m, h, g\}$$

即当某一类认知关系在当前证据集中尚未出现时，能够引入该关系的候选将获得更高的新增覆盖收益；若该类关系已经被充分覆盖，则相应收益自动减弱。对于知识点覆盖，设目标题目的细粒度知识点集合为$\mathcal{K}(q_t)$，则可定义：

$$\Delta_k(i,S)=\frac{|(\bigcup_{h_j\in S\cup\{h_i\}}\mathcal{K}(q_j))\cap\mathcal{K}(q_t)|-|(\bigcup_{h_j\in S}\mathcal{K}(q_j))\cap\mathcal{K}(q_t)|}{|\mathcal{K}(q_t)|+\varepsilon}$$

其中ε为防止分母为零的平滑项。该项鼓励最终证据集在与当前题目直接相关的知识点上形成更完整的覆盖，而不是反复选择同一局部知识片段。

除了覆盖不足，候选之间还可能存在内容的高度重复。因此，本文进一步定义冗余惩罚项：

$$\mathrm{Red}(h_i,S)=\max_{h_j\in S}\mathrm{Sim}\,(h_i,h_j)$$

其中 $\mathrm{Sim}\,(h_i,h_j)$用于衡量候选 h_i与已选证据 h_j的重复程度。为兼顾知识内容、认知角色与题目语义，本文将其写为：

$$\mathrm{Sim}\,(h_i,h_j)=\mu_k\frac{|\mathcal{K}(q_i)\cap\mathcal{K}(q_j)|}{|\mathcal{K}(q_i)\cup\mathcal{K}(q_j)|}+\mu_r\frac{\langle\mathbf{a}_i,\mathbf{a}_j\rangle}{\|\mathbf{a}_i\|_1\|\mathbf{a}_j\|_1+\varepsilon}+\mu_s\cos\,(\tilde{e}_{q_i}^{sem},\tilde{e}_{q_j}^{sem})$$

其中$\mathbf{a}_i=[a_i^p,a_i^m,a_i^h,a_i^g]$表示候选的关系激活向量，$\mathbf{e}_{q_i}^{sem}$ 表示题目侧语义先验。该定义意味着：若两条候选不仅考查知识点高度重合，而且承担相似的认知角色、题目语义又接近，则它们被视为高度冗余，后续同时进入最终证据集的必要性就会下降。

综合基础证据效用、认知覆盖增益与冗余惩罚后，候选h_i在当前已选集合S条件下的集合级排序分数定义为：

$$\mathrm{Score}(h_i\mid S)=U_i+\beta\,\mathrm{Cov}(h_i\mid S)-\gamma\,\mathrm{Red}(h_i,S)$$

其中β和γ分别控制覆盖奖励与冗余惩罚的相对强度。由此，第二阶段通过如下贪心过程生成最终认知证据集合：初始时令$S=\emptyset$，首先选择基础证据效用最高的候选：

$$h^{(1)}=\arg\max_{h_i\in C_u^t}U_i$$

随后在每一步从剩余候选中选择集合级分数最高者：

$$h^{(l)}=\arg\max_{h_i\in C_u^t\setminus S}\mathrm{Score}(h_i\mid S)$$

并更新 $S\leftarrow S\cup\{h^{(l)}\}$，直至选满$K$条证据。最终得到：

$$E_u^t = \{h^{(1)}, h^{(2)}, \dots, h^{(K)}\}$$

3.4 分层认知上下文构造器

经过两阶段认知证据检索后，系统已经从学生冗长历史中筛选出一个小规模高质量证据集合

$$\mathcal{E}_u^t = \{h_{i_1}, h_{i_2}, \dots, h_{i_K}\}$$

其中每条h_{i_k}都是与当前目标题目q_t在概念、认知层级、协同路径或时间有效性上具有较强解释力的历史记录。接下来的问题不再是找哪些证据，而是如何把这些证据组织成模型能够理解且低噪声的输入。为此，本节设计分层认知上下文构造器，将最终证据集合组织为“全局摘要引导 + 局部证据支撑”的两层结构。

这种设计的出发点在于：知识追踪场景中的历史证据并不是平铺直叙的同质文本片段，它们在教学逻辑中扮演着不同角色。有些证据用于说明学生近期薄弱概念，有些用于反映前置知识是否掌握，有些用于支撑同层级迁移判断。如果简单把所有历史记录按文本相似度堆叠为一长段上下文，模型很难区分当前学生整体处于什么状态与具体哪些历史证据支撑这一判断。

3.4.1 全局认知摘要层

全局认知摘要层的作用，是在正式展开局部证据之前，先为编码器提供一条关于学生当前局部状态的紧凑概括。该摘要并不承担精细推理任务，而是用于回答一个更宏观的问题：在进入具体历史证据之前，当前学生大致处于什么样的认知状态。

本文将摘要记为D_u^t。它基于当前时刻的短期认知先验、近期高价值历史记录及其作答反馈生成，由 LLM 产生，最终形式必须被约束为一句或两句简洁文本。例如，它可以表达为“近期在概念 A 的理解—应用迁移上连续失误”或“基础概念记忆较稳定，但同层级应用题表现波动较大”。这类摘要的价值不在于替代原始证据，而在于帮助后续编码器先建立一个全局视角，再去理解后面展开的局部支撑证据。

3.4.2 局部证据层

局部证据层是分层认知上下文构造器的核心。它直接承接上一节输出的最终证据集合$\mathcal{E}_u^t$，并将每条高价值历史记录组织为结构清晰、语义连贯的文本块。

对于每条历史交互，提取其分层语义 ID、协同信息、认知层级、题目文本和历史作答结果，并将这些属性改写为半结构化的自然语言模板，以供文本编码器提取高维语义特征。

对于任意最终证据$h_{i_k} = (q_{i_k}, r_{i_k}, \tau_{i_k})$，本文构造其对应的文本块$E_{i_k}$。每个证据块至少包含以下信息：

- 题目级语义先验，即该题所属的分层语义类别；
- 与目标题相关的认知层级信息；
- 必要的协同或结构支撑信息；
- 原始题目内容或其核心语义表达；
- 学生在该题上的真实作答结果。

与扁平拼接不同，这里的局部证据层不是简单堆叠，而是带有明确排序依据的证据序列。由于上一节已经通过两阶段检索器筛出 Top-K 高价值证据，因此本节先按第二阶段得分分组或主排序，再在组内按时间顺序排列，同时保留其已被筛选过的语义前提。这样一来，局部证据层既保留了知识追踪任务所需要的时间演化信息，又避免了原始长序列中大量低价值历史的干扰。

在得到全局认知摘要D_u^t和局部证据块 $\{E_{i_1}, E_{i_2}, \dots, E_{i_K}\}$后，本文将最终认知上下文构造为

$$T_{\text{ctx}}^{u,t} = \text{Concat}(D_u^t, E_{i_1}, E_{i_2}, \dots, E_{i_K})$$

其中$\text{Concat}(\cdot)$表示按既定顺序拼接文本片段的操作。这里采用“先摘要、后证据”的组织方式，原因在于：摘要先给出学生当前局部状态的全局指引，后续证据块再对这一全局判断进行逐条支撑。这样构造出的上下文，不再是若干相似历史题目的平铺列表，而是一个具有清晰内部层次的认知上下文：上层给出当前状态的整体概括，下层提供可追溯的教学证据。

从形式上看，$T_{\text{ctx}}^{u,t}$仍然是一段自然语言文本；但从功能上看，它已经不再是普通的拼接结果，而是由两阶段检索器和分层构造器共同组织出来的“教学证据表达体”。这也正是本文区别于普通文本堆叠方法的关键所在。

3.5 稳态认知语义融合器

在认知上下文序列化完成后，任务的最后阶段是将自然语言文本转换为深度模型可处理的连续表征，并执行端到端的知识状态预测。本文首先利用预训练文本编码器将构建的提示词序列映射为高维语义向量$v_{\text{sem}} \in \mathbb{R}^{d_{\text{sem}}}$。

先前的研究在引入外部特征时，通常采用简单的向量拼接。但是在知识追踪任务中，粗鲁的将高维语义向量与低维的题目 ID 嵌入直接拼接，易引发维度灾难，导致主干网络原有的时序建模能力被巨大的语义噪声影响。所以本文提出了一种双重特征融合框架。该框架作为一个轻量级的即插即用模块，可无缝嵌入至各类基于序列建模的知识追踪基线模型中，具体包含以下两个阶段：

1. 早期门控注入

在底层输入阶段，为了保护目标问题原有 ID 嵌入e_{id}的纯净度，模型引入了一个可学习的非线性门控网络，动态决定特征的吸收比例。设门控权重为$g \in [0,1]^d$，其计算与融合公式如下：

$$\bar{v}_{sem} = W_v v_{sem} + b_v, \bar{v}_{sem} \in \mathbb{R}^d$$

$$g = \sigma\left(W_g[e_{id} \oplus \bar{v}_{sem}] + b_g\right)$$

$$e_{\text{fused}} = g \odot e_{id} + (1 - g) \odot \bar{v}_{sem}$$

其中σ为 Sigmoid 激活函数，$\oplus$表示向量拼接，$\odot$为逐元素相乘。通过这一机制，模型能够实现自适应调节：对于高频常见题目，模型更多依赖自身学习到的离散 ID 表征；而对于缺乏充足训练数据的生僻题或冷启动样本，模型会自发放大$1 - g$的权重，充分吸收 Cognitive-RAG 召回的外部认知语义支撑。

2. 晚期特征融合

在主干网络处理完历史序列，并输出学生当前隐含知识状态的表征向量h_{state}后，在预测层之前，本文引入了特征线性调制机制（Feature-wise Linear Modulation, FiLM）进行认知调整。利用高维语义向量v_{sem}生成独立的缩放系数γ和偏移系数β：

$$\gamma = \tanh\left(\mathbf{W}_\gamma v_{sem} + \mathbf{b}_\gamma\right)$$

$$\beta = \mathbf{W}_\beta v_{sem} + \mathbf{b}_\beta$$

$$h_{\text{modulated}} = h_{\text{state}} \odot (1 + \gamma) + \beta$$

这一步在数学逻辑上，相当于利用检索模块提供的高信噪比教学先验（如发现该学生缺乏关键前置知识），对主干网络推演出的知识状态进行最后一步的干预与微调。最终，调制后的状态向量$h_{\text{modulated}}$被送入全连接层输出最终的作答正确概率$\hat{r}_t$。

该双重融合架构在完全保留各种知识追踪主干网络原有结构优势与时序建模能力的同时，压榨了 Cognitive-RAG 提供的复杂教学特征，确保了语义信息的平滑注入与稳定收敛。